

SPOTIFY PLAYLIST DATASET CHALLENGE

ANÁLISIS DE SIMILITUD ENTRE PLAYLISTS DEL MILLION PLAYLIST DATASET


UN ENFOQUE DE MINERÍA DE DATOS BASADO EN ATRIBUTOS MUSICALES Y TÉCNICAS DE CLUSTERING

¿Podemos predecir los gustos en playlist
a través del tiempo?


Por: Paula Velosa– Fabián López
Grupo 4 – Minería de Datos 2025-1

ÍNDICE DE LA PRESENTACIÓN

- 1 Introducción y Motivación
- 2 El Dataset: Fuentes y Características
- 3 Metodología: Proceso KDD Aplicado
- 4 Resultados Principales
 - Clustering de Playlists
 - Reglas de Asociación
 - Desafíos en la Predicción
- 5 Conclusiones y Trabajo Futuro



Introducción y Motivación




¿POR QUÉ ANALIZAR LA SIMILITUD ENTRE PLAYLISTS?

- 1 En la era del streaming, las playlists son manifestaciones de gustos musicales individuales y colectivos.
- 2 Comprender las relaciones entre ellas es fundamental para crear sistemas de recomendación más eficientes y personalizados.
- 3 **Objetivo del Proyecto:** Identificar patrones y agrupaciones naturales de playlists en el Million Playlist Dataset (MPD) para entender las preferencias de los usuarios.


NOTAS ADICIONALES

- El dataset permite analizar estructuras musicales sin usuario.
- Se pueden encontrar patrones latentes en gustos musicales.
- Las playlists actúan como proxies de preferencias temáticas.
- Se plantean posibles extensiones usando el MPD completo o metadata externa (géneros, popularidad).






El Dataset y su Enriquecimiento



DIMENSIONALIDAD

Descripción del conjunto

- **Playlists:** 10.000 registros.
- **Columnas:** 6 variables por Playlist – 8 variables por canción.
- **Pistas visibles:** Hasta 100 por playlist.
- **Formato anidado:** Cada playlist contiene una lista de canciones.



DESCRIPCIÓN DEL CONJUNTO

Recomendación musical automatizada

- 1 Reto de completación de playlists en el RecSys Challenge **2018**
- 2 10.000 playlists parciales (extraídas del Million Playlist Dataset completo del Challenge).
- 3 Cada registro incluye detalles como el título de la playlist, el título de las pistas y metadatos adicionales como la última fecha de edición y el número de playlists editadas.
- 4 Originalmente el objetivo de este Challenge era entrenar un modelo con el MPD (ya no disponible al público) para predecir canciones faltantes en playlists incompletas en el Challenge Set.

VENTANA DE TIEMPO🕒

Descripción del conjunto

Challenge Set - Extraído del MPD

Los datos abarcan playlists públicas creadas por usuarios estadounidenses desde **enero de 2010** hasta **noviembre de 2017**




ENRIQUECIMIENTO DE DATOS


Base: Challenge set del Million Playlist Dataset (MPD) de Spotify, con 10,000 playlists parciales.

Se integraron datos de 3 fuentes externas:

- 1 Spotify Web API:** Metadatos como popularidad y género.
- 2 MusicBrainz:** Metadatos de canciones como BPM y género
- 3 AcousticBrainz:** Atributos acústicos detallados (ej. danceability, energy, valence, moods).



Metodología General: Proceso KDD



PIPELINE DE DESCUBRIMIENTO DE CONOCIMIENTO (KDD)

Recomendación musical automatizada

1

Integración y Limpieza: Fusión de fuentes y manejo de datos faltantes.

2

Análisis Exploratorio (EDA): Entendimiento inicial de los datos y sus distribuciones.

3

Preprocesamiento: Normalización y reducción de dimensionalidad (PCA, UMAP).

4


Minería de Datos:

- **Clustering (K-Means, HDBSCAN):** para agrupar playlists.
- **Reglas de Asociación (FP-Growth):** para encontrar co-ocurrencias de canciones.


5

Predicción y Evaluación: Clasificación de playlists en los clústeres identificados.


ANÁLISIS EXPLORATORIO (EDA): HALLAZGOS




Tamaño de Playlists: La mayoría de las playlists son cortas, con una media de ~14 canciones conocidas.



Temáticas Dominantes: Los títulos de playlists sugieren un predominio de "Country", "Rock", "Pop", "Oldies" y "Party".



Características Agregadas: Se crearon 63 atributos numéricos por playlist (ej. *avg_energy*, *avg_danceability*) para caracterizarlas.



DESCRIPCIÓN

de los datos

1


Dimensionalidad: Bastante Alta y variable; muchas combinaciones posibles de canciones, artistas y títulos.

2


Dispersión: Bastante baja, Playlists altamente únicas.
Algunas canciones/artistas muy frecuentes; otras raras.

3

Resolución: Alta, alto nivel de detalle musical (URI, duración, etc.).
Sin datos de usuario ni fechas individuales por playlist.



Metodología de Clustering



AGRUPANDO PLAYLISTS POR AFINIDAD MUSICAL



Objetivo: Segmentar las playlists en grupos homogéneos según sus características musicales agregadas.

Algoritmo Principal: HDBSCAN. -
(Enfoque híbrido)

Se eligió sobre K-Means por su capacidad para encontrar clústeres de diferentes densidades e identificar "ruido" (playlists atípicas)

Identificó una estructura muy granular:

82 clústeres + 1 clúster de ruido (-1), reflejando la alta diversidad del dataset.



RESULTADOS DEL CLUSTERING: PERFILES TEMÁTICOS

Los 7 Perfiles Principales de Playlists

Cluster 0: "Fiesta Retro" (Rock, Rap, Country)

Cluster 1: "Country & Rock Party".


Cluster 2: "Vibras Chill & Good Vibes".


Cluster 3: "Retro Ecléctico" (Oldies Country-Rock).

Cluster 4: "Éxitos Retro Multigénero".


Cluster 5: "Verano & Fiesta" (Nuevos éxitos, Rap, Dance).

Cluster 6: "Personal/Misceláneo".






Metodología de Reglas de Asociación




ENCONTRANDO CANCIONES QUE "VAN JUNTAS"

Objetivo: Identificar conjuntos de canciones que aparecen frecuentemente juntas.



Se usó el algoritmo **FP-Growth** en una matriz de transacciones (playlist-canción).
Se estableció un **soporte mínimo de 0.5%** (presente en al menos ~40 playlists).




Métricas Clave:

- **Soporte:** Frecuencia de la combinación de canciones.
- **Confianza:** Probabilidad de encontrar B si A ya está presente.
- **Lift:** Qué tan fuerte es la asociación comparada con la casualidad. Un $\text{Lift} > 1$ indica una relación positiva.

RESULTADOS DE LAS REGLAS DE ASOCIACIÓN

Asociaciones Significativas Intra-Cluster



El análisis fue más revelador al aplicar las reglas dentro de cada clúster:

Cluster 0:


	A_names	A_artists	B_names	B_artists	support	confidence	lift
0	XO TOUR Llif3	Lil Uzi Vert	Tunnel Vision	Kodak Black	0.025735	0.636364	24.727273
1	XO TOUR Llif3	Lil Uzi Vert	Come Get Her	Rae Sremmurd	0.018382	0.454545	20.606061
2	Come Get Her	Rae Sremmurd	XO TOUR Llif3	Lil Uzi Vert	0.018382	0.833333	20.606061

Regla 0: Lift de 24.7, indicando que estas canciones co-ocurren casi 25 veces más de lo esperado.


Cluster 5:

	A_names	A_artists	B_names	B_artists	support	confidence	lift
0	Never Enough	Logic	Innermission	Logic	0.001907	0.833333	437.000000
1	Jingle Bells (feat. The Puppini Sisters)	Michael Bublé	Santa Claus Is Coming To Town	Michael Bublé	0.001907	0.833333	364.166667
2	Santa Claus Is Coming To Town	Michael Bublé	Jingle Bells (feat. The Puppini Sisters)	Michael Bublé	0.001907	0.833333	364.166667

Regla 0: Lift de 437, una asociación extremadamente fuerte, probablemente por ser del mismo álbum o artista y populares en un nicho.



El Reto de la Predicción





PREDICIENDO EL CLÚSTER DE UNA PLAYLIST

Objetivo: Entrenar un modelo de clasificación (XGBoost, Bi-LSTM) para predecir la etiqueta de clúster de una playlist.


Resultado Inicial:

Se obtuvo una Accuracy del 41%






Análisis de Resultados de la Predicción




PREDICIENDO EL CLÚSTER DE UNA PLAYLIST

El Problema del Desbalance de Clases

- El clúster de "ruido" (-1) identificado por HDBSCAN contenía el 41% de todas las playlists
- El modelo aprendió una estrategia simple: **predecir siempre la clase mayoritaria ("ruido")**.
- El recall para todos los clústeres significativos (0-81) fue de 0.00.
- **Conclusión de esta fase:** El modelo no logró diferenciar los perfiles temáticos; la accuracy del 41% solo refleja el tamaño de la clase más grande.



Discusión y Limitaciones




PREDICIENDO EL CLÚSTER DE UNA PLAYLIST


¿Por qué fue tan difícil la predicción?

● **Desbalance Extremo:** Un clúster domina el dataset, sesgando el aprendizaje de los modelos.


● **Complejidad Intrínseca:** Existe un solapamiento considerable entre los clústeres en el espacio de características agregadas.

● **Insuficiencia de Atributos:** Las características (promedios de energía, tempo, etc.) podrían no ser suficientemente discriminativas para capturar la esencia única de cada clúster.






Conclusiones y Aportes Principales




CONCLUSIONES





- Se desarrolló un **pipeline de minería de datos completo y reproducible** para el análisis de playlists.
- **El clustering** (especialmente con HDBSCAN) **fue exitoso al segmentar las playlists** en nichos temáticos coherentes y musicalmente relevantes.
- La minería de **reglas de asociación reveló afinidades fuertes y no obvias entre canciones**, especialmente a nivel de clúster, conocimiento valioso para sistemas de recomendación.
- Aunque la predicción directa del clúster falló, **el análisis no supervisado proporcionó una comprensión profunda** de la estructura de las preferencias colectivas en el dataset.



Trabajo Futuro




PRÓXIMOS PASOS

-  **Mejorar la Predicción:** Aplicar técnicas para manejar el desbalance de clases (ej. re-muestreo, ponderación de clases).
-  **Modelos más Sofisticados:** Entrenar modelos secuenciales que consideren el orden de las canciones para predicción de la siguiente pista (next-track prediction).
-  **Expandir los Datos:** Incorporar un volumen mayor de playlists para robustecer los patrones encontrados.
-  **Ingeniería de Características:** Explorar atributos más discriminativos para diferenciar mejor los clústeres.



¡Gracias!

¿Preguntas?



Contacto:

pvelosa@unal.edu.co
flopezgo@unal.edu.co